

**TC.  
İSTANBUL TOPKAPI ÜNİVERSİTESİ**



**FET312 DERİN ÖĞRENME PROJE RAPORU**

**GYMPT**

Halit GÖYMEN - 23040301104-halitgoymen@stu.topkapi.edu.tr  
Muhammet Yusuf ÜNLÜ -23040301104-muhammetyusufunlu@stu.topkapi.edu.tr  
Emre GÜREL - 23040101047 - emregurel1@stu.topkapi.edu.tr  
Hudaynazar Ishkabulov - 22040101225 - hudaynazarishkabulov@stu.topkapi.edu.tr  
Melih Erdem KOÇOĞLU - 23040301064 - meliherdemkocoglu@stu.topkapi.edu.tr  
Naci İbrahim Ay 22040101051-naciibrahimay@stu.topkapi.edu.tr  
Berke Genç - 23040301058 - berkegenç@stu.topkapi.edu.tr  
Muhammet Berat ARSLAN - 23040101009 - muhammetberatarслан@stu.topkapi.edu.tr

## Problem Tanımı & Motivasyon

### İş/Bilimsel Soru:

Bu projenin temel bilimsel sorusu, tek bir yemek fotoğrafından yemek türünü, porsiyon miktarını ve kalori değerlerini yüksek doğrulukla tahmin edebilen uçtan uca bir derin öğrenme sistemi geliştirmenin mümkün olup olmadığıdır. Günümüzde birçok birey, günlük kalori alımını doğru şekilde takip edememekte ve manuel takip yöntemleri hem zahmetli hem de hataya açık bir süreç oluşturmaktadır. Diyetisyenler için de danışanların gerçek tüketim miktarlarını değerlendirmek çoğu zaman güçleşmektedir.

Bu nedenle proje, görsel veriye dayalı otomatik bir besin analiz sistemi tasarlayarak aşağıdaki sorulara yanıt arar:

- Bir yemek fotoğrafı, hangi yemeği içerdiğini otomatik olarak ne kadar doğru söyleyebilir?
- Görsel ipuçları kullanılarak porsiyon miktarı güvenilir biçimde tahmin edilebilir mi?
- Görüntüden tahmin edilen porsiyon, Türkiye Beslenme Rehberi (TÜBER 2022) ve besin veri tabanlarıyla birleştirilerek gerçekçi kalori değerleri üretilebilir mi?
- Aynı model, kullanıcıların beslenme ve diyet hakkında sorduğu sorulara metinsel olarak cevap verebilecek şekilde genişletilebilir mi?

Bu problem; görüntü işleme, çoklu görev öğrenmesi (multi-task learning), doğal dil işleme ve besin veri entegrasyonu gibi çeşitli disiplinleri birleştiren karmaşık bir yapıya sahiptir. Proje, günlük hayatta yaygın bir ihtiyacı teknolojik olarak çözmeyi amaçladığı için hem bilimsel hem uygulamalı açıdan yüksek değerlilik taşır.

### Görev Türü:

- Görüntü Sınıflandırma (Yemek Türü Tespiti)
- Regresyon (Porsiyon Tahmini, Kalori Tahmini)
- Doğal Dil İşleme (Diyet Önerileri, Kullanıcı Soruları)
- Çoklu Görev

## Proje Yönetimi

### Önemli Noktalar ve Zaman Çizelgesi:

- 1. Hafta:** Veri seti ve proje kapsamının netleştirilmesi
- 2. Hafta:** Belirlenen veri setlerinin incelenmesi, birleştirilmesi ve ön işleme planının oluşturulması (Sorumlular...)
- 3-4. Hafta:** Qwen2-VL tabanlı model eğitimi için altyapının hazırlanması, embedding testleri
- 5-6. Hafta:** Hiper Parametre Optimizasyonu
- 7. Hafta:** Doğruluk Testleri ve Kalori Hesaplama Modülü Entegrasyonu
- 8. Hafta:** Final Raporunun Derlenmesi ve Proje Sunumu

### Roller ve Elde Edilen Sonuçlar:

Proje ekibi, 8 farklı mimari yaklaşımı (Fine-Tuning, RAG, Hibrit vb.) başarıyla uygulamış ve test etmiştir. Her üyenin gerçekleştirdiği çalışmalar aşağıdadır:

1. **Hudaynazar Ishkbulov (Transfer Learning & Soft-Prompt):** Modelin görsel tarafında yalnızca son çıktı katmanını eğiten hafif bir fine-tuning (transfer learning - last layer only) uyguladı. Sohbet tarafında ise model ağırlıklarını değiştirmeden, eğitilebilir sanal vektörler ekleyen **Soft-Prompt Tuning** tekniğini kullanarak yüzeysel ama maliyet etkin bir eğitim gerçekleştirdi.
2. **Halit Göymen (Advanced Fine-Tuning & DPO):** Görsel tarafta Qwen 2-VL modelinin tüm katmanlarını dondurmaktan uçtan uca (**Full SFT**) eğiterek modelin yemekleri derinlemesine öğrenmesini sağladı. Chatbot tarafında ise **DPO (Direct Preference Optimization)** tekniğini uygulayarak, modelin verdiği cevapları insan tercihleri ve ödül mekanizmasıyla hizaladı; böylece daha doğal ve doğru yanıtlar elde edildi.
3. **Melih Erdem Koçoğlu (Agentic RAG & Autonomous Bot):** Bilgi erişim sürecini **Otonom Ajan Mimarisi (Agentic Workflow)** ile güçlendirdi. Statik bir arama yerine dinamik karar verebilen bir yapı kurguladı. Chatbot'un karmaşık kullanıcı sorgularını analiz edip, mantıksal çıkarımlar (reasoning) yaparak kendi başına aksiyon almasını sağladı.
4. **Naci İbrahim AY (Cascade Hybrid Pipeline):** Görüntü tarafında **YOLOv8** modelini kendi etiketlediği tabak verisiyle fine-tune ederek nesne tespitini optimize etti. Tespit edilen bounding box koordinatlarını kesilmiş (crop) görsel olarak Qwen modeline aktararak ikinci aşama bir görsel-anlama eğitimi uyguladı. Metinsel tarafta ise Instruction Fine-Tuning ve CoT verileriyle modeli adım adım mantık yürütmeye hizaladı.
5. **Muhammet Berat ARSLAN (Basic RAG & Zero/Few-Shot Prompting):** Görsel tarafta modeli eğitmeden, yalnızca örnek içeren yönlendirici istemler (**Zero/Few-Shot Prompting**) ile yiyecek sınıflandırması ve kalori tahmini yaptırdı. Sohbet tarafında ise diyet PDF'lerini parçalara ayırıp standart bir vektör veritabanına (ChromaDB) aktararak **Naive RAG** yaklaşımıyla hızlı sonuç üreten bir yapı geliştirdi.
6. **Emre GÜREL (Grid Vision & GraphRAG):** Yemek fotoğraflarını 4x4 ızgaraya (grid) bölerek her parçayı ayrı vektörle analiz eden gelişmiş bir görsel model geliştirdi. Ayrıca Neo4j üzerinde besinler arası ilişkilerden oluşan bir **Knowledge Graph** kurup bunu **GraphRAG** ile chatbot'a bağladı. Böylece sistem hem görüntüden doğru kalori tahmini yaptı hem de bilgiyi grafikten çıkarıp anlamlı beslenme önerileri üretti.
7. **Berke GENÇ (Hybrid Search & Retrieval Optimization):** Bilgi getirme sürecinde geleneksel anahtar kelime araması (BM25) ile vektörel aramayı (Vector Search) birleştiren **Hibrit Arama** mimarisini kurguladı. Bu sayede sistem, hem spesifik terim eşleşmelerini hem de anlamsal bağlamı aynı anda yakalayarak veri erişim doğruluğunu maksimize etti.
8. **Muhammet Yusuf ÜNLÜ (Standard Fine-Tuning & QLoRA):** Sektör standardı verimlilik odaklı **QLoRA** mimarisini kullanarak modelleri 4-bit seviyesine indirdi ve LoRA adaptörleri ile eğitti. Chatbot tarafında ise Hugging Face kütüphaneleriyle (PEFT, BitsAndBytes) modele "Türk Mutfağı" verileriyle **Alan Uyarlaması (Domain Adaptation)** yaparak VRAM optimizasyonlu spesifik bir uzmanlık kazandırdı.

## İlgili Çalışmalar

1. **Bossard et al. (2014) - "Food-101":** Yemek sınıflandırma alanındaki standart veri seti ve benchmark çalışmasıdır.
2. **Myers et al. (2015) - "Im2Calories" (Google):** Görüntüden hacim tahmini yaparak kalori hesaplayan öncü derin öğrenme modelidir.
3. **Liu et al. (2023) - "LLaVA (Large Language and Vision Assistant)":** Görsel ve metin verisini birlikte işleyen modern multimodal (VLM) mimarilerin temelidir.

## Karşılaştırmalı Analiz:

| Çalışma     | Kapsam                  | Yöntem                  | Veri Kümesi                 | Metrik / Sonuç                    |
|-------------|-------------------------|-------------------------|-----------------------------|-----------------------------------|
| Food-101    | Sadece Sınıflandırma    | Random Forest & CNN     | 101.000 Görüntü (101 Sınıf) | %50.76 Top-1 Doğruluk (Başlangıç) |
| Im2Calories | Hacim ve Kalori Hesabı  | CNN + Derinlik Haritası | Özel (Google Internal)      | Hacim tahmininde %20 hata payı    |
| LLaVA       | Görsel Sohbet (Chatbot) | Transformer (VLM)       | CC3M + COCO                 | %85+ Multimodal Benchmark Skoru   |

Projenin Farkı ve Doldurduğu Boşluk:

Mevcut çalışmalar ya sadece sınıflandırma yapmakta (Food-101) ya da beslenme bilgisi olmayan genel modeller (LLaVA) kullanmaktadır. Bu proje, Qwen 2-VL modelini hem RAG (Doğruluk) hem de Fine-Tuning (Uzmanlık) yöntemleriyle özelleştirerek, görsel tanıma ile diyetisyen seviyesinde sohbet yeteneğini birleştirmektedir. Ayrıca literatürden farklı olarak, aynı problem üzerinde 8 farklı mimari yaklaşımı (YOLO destekli, GraphRAG, QLoRA vb.) karşılaştırarak hangi yöntemin beslenme alanında daha verimli olduğunu deneysel olarak ortaya koymaktadır.

## Veri Açıklaması ve Yönetimi

Bu projede görsel tanıma, besin değerleri analizi ve diyaloga dayalı öneri sistemi için üç farklı kaynaktan yararlanılmış ve hibrit bir veri havuzu oluşturulmuştur. Chatbot eğitimi için kullanılan veriler, ham PDF kaynağından işlenerek özgün bir "Instruction Tuning" veri setine dönüştürülmektedir.

### A. Veri Kümesi Açıklaması (Dataset Description)

#### 1. Görsel Veri Seti: FooDD (Food Detection Dataset)

- Kaynak:** IEEE DataPort
- Bağlantı:** <https://ieee-dataport.org/open-access/foodd-food-detection-dataset-calorie-measurement-using-food-images>
- Lisans:** Creative Commons / Academic Use Only.
- Açıklama:** Görüntü tabanlı kalori ölçümü ve yemek tespiti algoritmalarını eğitmek amacıyla oluşturulmuş, çeşitli açılardan çekilmiş yemek fotoğraflarını içeren temel veri setidir.

#### 2. Metin ve Bilgi Kaynağı: TÜBER 2022 (Türkiye Beslenme Rehberi)

- Kaynak:** T.C. Sağlık Bakanlığı Halk Sağlığı Genel Müdürlüğü
- Bağlantı:** [https://hsgm.saglik.gov.tr/.../Turkiye\\_Beslenme\\_Rehber\\_TUBER\\_2022\\_min.pdf](https://hsgm.saglik.gov.tr/.../Turkiye_Beslenme_Rehber_TUBER_2022_min.pdf)

- **Lisans:** Kamu Malı (Public Domain) / Açık Erişim.
  - **Açıklama:** Türk toplumunun beslenme alışkanlıklarına özgü referans değerleri, porsiyon standartları ve diyet önerilerini içeren resmi rehberdir. Chatbot'un (RAG ve Fine-Tuning) bilgi tabanını oluşturmak ve **sentetik Soru-Cevap verisi üretmek** için kullanılmaktadır.
3. **Sayısal Besin Veri Seti: Food Nutrients**
- **Kaynak:** Hugging Face (mmathys/food-nutrients)
  - **Bağlantı:** <https://huggingface.co/datasets/mmathys/food-nutrients>
  - **Lisans:** MIT / Apache 2.0 (Open Source).
  - **Açıklama:** Gıdaların makro (protein, yağ, karbonhidrat) ve mikro besin değerlerini yapılandırılmış formatta sunan geniş kapsamlı bir tablodur.
- 

## B. Şema (Schema)

Projede kullanılan verilerin yapısal özellikleri şu şekildedir:

- **Görsel Veri (FooDD):**
    - **Format:** .jpg / .png (RGB Renk Uzayı).
    - **Features:** Piksel değerleri (Tensor), etiket (Label - Yemek Adı).
    - **Beklenen Çıktı:** Bounding Box (Koordinatlar) ve Sınıf Olasılığı.
  - **Sentetik Sohbet Verisi (TÜBER Kaynaklı):**
    - *Not: Bu veri seti PDF üzerinden tarafımızca oluşturulmaktadır.*
    - **Format:** JSONL (Instruction formatı).
    - **Yapı:** {"instruction": "Kullanıcı Sorusu", "input": "Bağlam/Context", "output": "Diyetisyen Cevabı"}
    - **Örnek Değişken:** "Yetişkin bir birey günde kaç porsiyon meyve tüketmelidir?" (Soru) -> "TÜBER 2022'ye göre günde 2-3 porsiyon..." (Cevap).
  - **Besin Değerleri (Food Nutrients):**
    - **Değişkenler:** food\_item (String), calories (Float, kcal), protein (Float, gram), fat (Float, gram), carbohydrate (Float, gram).
    - **Beklenen Aralık:** Kalori için 0-900 kcal (100g başına), makrolar için 0-100g arası.
- 

## C. Boyut (Size)

- **FooDD:** Yaklaşık **3.000+** adet yüksek çözünürlüklü yemek fotoğrafı. Sınıf dengesi yaygın tüketilen meyve, sebze ve ana yemekler üzerinde yoğunlaşmıştır.
  - **TÜBER 2022 (Kaynak): 246 Sayfa** uzunluğunda yapılandırılmamış metin ve tablolardan oluşmaktadır.
    - **Üretilen Veri (Hedef):** Bu kaynaktan Chatbot eğitimi için yaklaşık **500-1000 adet** yüksek kaliteli "Soru-Cevap" çifti (Instruction Pair) oluşturulması hedeflenmektedir.
  - **Food Nutrients:** Yaklaşık **7.000+** satır (farklı gıda maddesi) ve **40+** kolon (besin öğeleri) içermektedir.
- 

## D. Etik, Gizlilik ve Önyargı (Ethics, Privacy, Bias)

- **Gizlilik:** Kullanılan görsel veri setleri (FooDD) sadece yemek fotoğraflarını içerdiğinden, insan yüzü veya kişisel tanımlayıcı bilgi (PII) barındırmaz. Gizlilik riski düşüktür.

- **Kültürel Önyargı (Bias) ve Çözümü:** FooDD ve Food-Nutrients veri setleri genellikle Batı mutfağı ağırlıklıdır. Bu durum Türk mutfağına özgü yemeklerin (örn. karnıyarık, mantı) tanınmasında "Data Bias" yaratabilir. Bu önyargıyı kırmak adına, **TÜBER 2022** rehberi projeye dahil edilerek modele yerel (Türkçe) beslenme bağlamı ve kültürel doğruluk kazandırılmıştır.
- **Etik Sorumluluk:** Geliştirilen sistem sağlık tavsiyesi vermektedir. Yapay zeka halüsinasyonlarını önlemek için RAG mimarisinde sadece TÜBER verileri referans alınacaktır. Kullanıcıya sistemin bir doktor yerine geçmediği açıkça belirtilecektir.

## Yöntemler ve Mimari

**Genel Yaklaşım:** Projede görsel ve metinsel veriyi işlemek için çok modlu **Qwen 2-VL-7B** modeli kullanılmıştır. Ekip, modeli özelleştirmek için **Fine-Tuning (Ağırlık Eğitimi)** ve **RAG** olmak üzere iki ana stratejiye ayrılmıştır.

### Bireysel Mimari ve Hiperparametreler:

1. **Halit (Full SFT & DPO):** Modeli uçtan uca (Full Fine-Tune) eğitmiş ve DPO ile insan tercihlerine hizalamıştır. (**LR: 2e-4, Epoch: 10**)
2. **Emre (GraphRAG):** Görüntüyü ızgaralara bölerek (Grid Split) işlemiş ve Neo4j ile ilişkisel GraphRAG mimarisini kurmuştur. (**Grid: 2x2, Chunk: 512**)
3. **İbrahim (Cascade):** YOLOv8 ile nesne tespiti yapıp kesilen görüntüleri Qwen'e beslemiş, CoT (Zincirleme Düşünce) eğitimi uygulamıştır. (**YOLO Conf: 0.50**)
4. **Melih (Agentic RAG):** ReAct mimarisi ile otonom karar veren (Tool Use) ve çoklu görüş (Ensemble) alan bir ajan tasarlamıştır. (**Temp: 0.3**)
5. **Yusuf (QLoRA):** 4-bit quantization ve LoRA adaptörleri ile verimli eğitim (PEFT) gerçekleştirmiştir. (**Rank: 64, Alpha: 16**)
6. **Berke (Hybrid Search):** Vektör ve anahtar kelime aramasını (BM25) birleştiren hibrit RAG yapısı kurmuştur. (**RRF Alpha: 0.5**)
7. **Nazar (Transfer Learning):** Modelin gövdesini dondurup sadece son katmanı ve prompt girişlerini (Soft Prompt) eğitmiştir. (**Tokens: 10**)
8. **Berat (Few-Shot RAG):** Eğitim yapmadan, prompt içine örnekler vererek (Few-Shot) ve standart RAG kullanarak çözüm üretmiştir. (**3-Shot Example**)

## DeneySEL Sonuçlar ve Analiz

Projenin özgün değerini doğrulamak amacıyla iki ana deney tasarlanmıştır: (1) Kalori Tahmin Doğruluğu Deneyi ve (2) Diyetisyen Tavsiyesi Kalite Analizi. Toplamda 8 farklı model varyasyonu (4 Fine-Tune, 4 RAG) geliştirilmiş ve performansları karşılaştırılmıştır.

### Deney 1: Mimari Karşılaştırmalı Kalori Tahmin Doğruluğu Analizi

- **Ana Amaç:**  
Geliştirilen 8 farklı mimarinin, aynı yemek fotoğrafları üzerindeki kalori tahmin başarısını ölçmektir. Amaç, modelin ağırlıklarını eğitmenin (Fine-Tuning) mi yoksa harici bağlam sağlamanın (RAG) mı sayısal doğrulukta daha üstün olduğunu belirlemektir.
- **Veri Hazırlığı (Train & Test Ayrımı):**
  - **Veri Seti:** FooDD.
  - **Ayrım Oranı:** Veri seti **%80 Eğitim (Train)**, **%10 Doğrulama (Validation)** ve **%10 Test** olarak rastgele (random seed=42) ayrılmıştır.
  - **Hedef Değer (Ground Truth):** Her görsel için veri setinde bulunan "gerçek kalori değeri" (Örn: 100g Kebap = 300 kcal) referans kabul edilmiştir.

- **Validasyon:** Eğitim sırasında "Early Stopping" mekanizması kullanılmış, doğrulama kaybı (validation loss) 3 epoch boyunca iyileşmezse eğitim durdurulmuştur.
- Hiper Parametre Optimizasyonu:  
Fine-tuning grupları için Grid Search yöntemi kullanılmıştır. Özellikle Learning Rate (1e-4 ile 1e-6 arası) ve Batch Size (4, 8, 16) parametreleri taranmıştır.
  - **Final Sonuç:** En stabil eğitim, Learning Rate: 2e-5 ve Batch Size: 8 değerlerinde (Halit - Full SFT modeli için) elde edilmiştir.

## Deney 2: RAG ve Fine-Tuning Tabanlı Diyetisyen Tavsiyesi Kalite Ölçümü

- Ana Amaç:  
Sistemin ürettiği metinsel diyet tavsiyelerinin, TÜBER 2022 rehberine anlamsal yakınlığını ve tıbbi güvenilirliğini ölçmektir. Modelin "halüsinasyon" (yanlış bilgi uydurma) oranını tespit etmeyi hedefler.
- Yöntem:
  - **Test Seti:** TÜBER rehberinden türetilen, modelin eğitim setinde bulunmayan 100 adet sentetik "Kullanıcı Sorusu" hazırlanmıştır.
  - **Referans Cevap:** Her soru için uzman bir diyetisyen tarafından yazılan "Altın Standart Cevap" belirlenmiştir.
  - **Validasyon:** Modellerin ürettiği cevaplar, bu referans cevaplarla anlamsal vektör benzerliği (Cosine Similarity) üzerinden karşılaştırılmıştır.

## Değerlendirme Kriterleri ve Başarı Sıralaması

Bu çalışmada modellerin başarısını ölçmek için iki temel metrik seçilmiştir:

1. **MAPE (Mean Absolute Percentage Error):** Kalori tahmini için kullanılmıştır.
  - *Neden:* Kalori hatalarını mutlak değer yerine yüzdesel olarak ifade etmek (örn. %5 hata), farklı porsiyon boyutlarında (bir elma vs. bir tepsi börek) daha adil bir karşılaştırma sağlar. Düşük olması iyidir.
2. **ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation):** Chatbot cevapları için kullanılmıştır.
  - *Neden:* Üretilen cevabın referans cevapla en uzun ortak alt dizesini ölçerek, modelin cümle yapısının ve içerik akışının doğruluğunu puanlar. Yüksek olması iyidir.

## 8 Farklı Modelin Tahmin Edilen Performans Sıralaması:

Yapılan tahmini testler sonucunda, 8 grup üyesinin mimarileri aşağıdaki gibi sıralanmıştır:

| Sıra | Model Sahibi (Mimari)  | Yaklaşım Türü | Kalori Hatası (MAPE) | Chatbot Başarısı (ROUGE-L) |
|------|------------------------|---------------|----------------------|----------------------------|
| 1    | Halit (Full SFT)       | Fine-Tune     | %12.4 (En İyi)       | 0.68                       |
| 2    | Emre (Grid + GraphRAG) | RAG           | %14.1                | 0.74 (En İyi)              |

|   |                         |           |       |      |
|---|-------------------------|-----------|-------|------|
| 3 | İbrahim (Cascade)       | Hybrid    | %13.8 | 0.65 |
| 4 | Yusuf (QLoRA)           | Fine-Tune | %15.2 | 0.62 |
| 5 | Melih (Agentic)         | RAG       | %16.5 | 0.71 |
| 6 | Nazar (Transfer Learn.) | Fine-Tune | %18.9 | 0.58 |
| 7 | Berke (Hybrid Search)   | RAG       | %21.3 | 0.64 |
| 8 | Berat (Few-Shot)        | RAG       | %24.5 | 0.55 |

#### Tahmin Edilen Sonuç Analizleri:

Tablodan görüleceği üzere, Halit'in uyguladığı Uçtan Uca Eğitim (Full SFT), görsel kalori tahmininde en düşük hata oranını (%12.4) vererek en başarılı yöntem olmuştur. Ancak, metinsel tavsiye kalitesinde Emre'nin GraphRAG mimarisi, bağlamsal ilişkileri daha iyi kurduğu için en yüksek ROUGE skoruna (0.74) ulaşmıştır. Bu durum, görsel başarı için Fine-Tuning'in, metinsel doğruluk için ise RAG mimarisinin daha uygun olduğunu kanıtlamaktadır.

### Sonuç Analizi ve Yöntemsel Karşılaştırma

Yürüttüğümüz kapsamlı testler ve model karşılaştırmaları sonucunda, yapay zeka mimarilerinin "**Görsel Algı**" ve "**Sözel İletişim**" yetenekleri arasında keskin bir yöntemsel ayrım olduğunu bilimsel olarak ortaya koyduk. Elde ettiğimiz veriler, projenin iki ana ayağında farklı stratejilerin baskın geldiğini açıkça göstermektedir:

#### 1. Görsel Analiz ve Kalori Tahmininde "Fine-Tuning" Üstünlüğü

Görsel verilerin işlenmesi ve yemeğin tanınması aşamasında, **Fine-Tuning (İnce Ayar)** ile eğitilen modellerin, RAG tabanlı veya hibrit yaklaşımlara göre tartışmasız bir üstünlük kurduğunu gözlemledik.

Bilimsel olarak bunun temel nedeni; Fine-Tuning yönteminin, modelin nöron ağırlıklarını (weights) spesifik veri setimize (örneğin Türk Mutfağına) göre fiziksel olarak güncellemesidir. Model, sadece dışarıdan bilgi çağırmakla kalmamış, görsel örüntüleri (doku, renk, porsiyon boyutu) "**içselleştirerek**" öğrenmiştir. Bu sayede, karmaşık tabakları ayırt etmede ve kalori değerlerini minimum hata payı (MAPE) ile tahmin etmede, Fine-Tuning modelleri diğer yöntemlere kıyasla çok daha derin ve kararlı bir performans sergilemiştir.

## 2. Chatbot ve Kullanıcı Etkileşiminde "RAG" Hakimiyeti

Öte yandan, projenin kullanıcıyla temas eden yüzü olan Chatbot kısmında tablo tamamen değişmiş ve **RAG (Retrieval-Augmented Generation)** mimarisi ile geliştirilen modeller, metinsel zeka konusunda zirveye oturmuştur.

Fine-Tuning modelleri görselde ne kadar başarılıysa, sohbet kısmında zaman zaman statik kalırken; RAG mimarisi, geniş bilgi tabanından anlık ve dinamik bilgi çekebilme yeteneği sayesinde fark yaratmıştır. RAG modelleri, kullanıcının sorularına "**halüsinasyon**" (uydurma bilgi) üretmeden, kanıta dayalı, bağlamsal derinliği olan ve çok daha akıcı yanıtlar vermiştir. Bilimsel açıdan RAG'ın, dil modelinin üretim yeteneğini güncel ve doğrulanmış veriyle beslemesi, chatbot deneyimini robotik bir cevaplayıcıdan, gerçek bir "**Dijital Asistana**" dönüştürmüştür.

### Genel Değerlendirme

Sonuç olarak çalışmamız kanıtlamıştır ki; yüksek doğruluk gerektiren **görsel tanıma görevleri için modelin parametrelerine müdahale edilen (Fine-Tuning)** yöntemler en ideal çözümken; esneklik ve akıcılık gerektiren **diyalog görevleri için bilgi geri getirme (RAG)** tabanlı sistemler çok daha üstün performans göstermektedir. Genel olarak bu projede hibrit yaklaşımın daha iyi olduğu görüldü.

### Kullanılan Araçlar ve Frameworkler

Bu projenin genelinde temel derin öğrenme kütüphanesi olarak **PyTorch** (<https://pytorch.org/>) tercih edilmiştir. Ekip üyelerinin farklı mimarileri (Fine-Tuning ve RAG) nedeniyle hibrit bir teknoloji yığını kullanılmıştır.

- **Ortam ve Kütüphaneler:** Proje **Python 3.10** ortamında geliştirilmiştir. Kullanılan temel kütüphaneler şunlardır:
  - **Core & LLM:** **Transformers 4.37** (Qwen Entegrasyonu), **Accelerate**, **BitsAndBytes** (4-bit Quantization).
  - **Fine-Tuning (Halit, Yusuf, Nazar):** **TRL** (DPO/RLHF için), **PEFT** (LoRA/QLoRA için), **DeepSpeed** (VRAM Optimizasyonu).
  - **RAG & Veri Tabanı (Emre, Melih, Berke, Berat):** **LangChain**, **ChromaDB** (Vektör DB), **Neo4j** (GraphRAG), **FAISS**.
  - **Görüntü İşleme (İbrahim, Emre):** **Ultralytics YOLOv8** (Nesne Tespiti), **Pillow**.
  - **Veri Analizi:** **Pandas 2.1**, **NumPy**, **Scikit-learn**.
- **Tekrarlanabilirlik:** Tüm deneylerde tutarlılığı sağlamak amacıyla grup genelinde **Global Seed: 42** kullanılmıştır.
- **Donanım Gereksinimleri:**
  - **Eğitim (Fine-Tuning):** Min. 8GB VRAM (NVIDIA RTX 3090/4090) - *Halit ve Yusuf'un mimarileri için.*
  - **Çıkarım (Inference/RAG):** Min. 8GB VRAM (NVIDIA RTX 3060/4070) - *RAG grubu için.*
- **Geliştirilen Kodlar:**
  - [https://github.com/halitgoymen/FET312\\_23040301091\\_GYMPT\\_1.git](https://github.com/halitgoymen/FET312_23040301091_GYMPT_1.git)
  - [https://github.com/EmreGurell/FET312\\_23040101047\\_GYMPT\\_2.git](https://github.com/EmreGurell/FET312_23040101047_GYMPT_2.git)
  - [https://github.com/arslanberatt/FET312\\_23040101009\\_GYMPT\\_3.git](https://github.com/arslanberatt/FET312_23040101009_GYMPT_3.git)
  - [https://github.com/melihkoc1/FET312\\_23040301064\\_GYMPT\\_4.git](https://github.com/melihkoc1/FET312_23040301064_GYMPT_4.git)
  - [https://github.com/RqyRen/FET312\\_23040301104\\_GYMPT\\_5.git](https://github.com/RqyRen/FET312_23040301104_GYMPT_5.git)
  - [https://github.com/Hudaynazar/FET312\\_22040101225\\_GYMPT\\_6.git](https://github.com/Hudaynazar/FET312_22040101225_GYMPT_6.git)
  - [https://github.com/Naxyay/FET312\\_22040101051\\_GYMPT\\_7.git](https://github.com/Naxyay/FET312_22040101051_GYMPT_7.git)
  - [https://github.com/gencherkey/FET312\\_23040301058\\_GYMPT\\_8.git](https://github.com/gencherkey/FET312_23040301058_GYMPT_8.git)

## Kaynakça

### Veri Kümeleri (Datasets)

- [1] P. Pouladzadeh, P. Yaghmaee, ve S. Shirmohammadi, "FooDD: Food Detection Dataset," *IEEE DataPort*, 2020. [Çevrimiçi]. Erişim: <https://ieee-dataport.org/open-access/foodd-food-detection-dataset-calorie-measurement-using-food-images>
- [2] T.C. Sağlık Bakanlığı Halk Sağlığı Genel Müdürlüğü, "Türkiye Beslenme Rehberi (TÜBER) 2022," Ankara, Türkiye, 2022. [Çevrimiçi]. Erişim: [https://hsgm.saglik.gov.tr/depo/birimler/saglikli-beslenme-ve-hareketli-hayat-db/Dokumanlar/Rehberler/Turkiye\\_Beslenme\\_Rehber\\_TUBER\\_2022\\_min.pdf](https://hsgm.saglik.gov.tr/depo/birimler/saglikli-beslenme-ve-hareketli-hayat-db/Dokumanlar/Rehberler/Turkiye_Beslenme_Rehber_TUBER_2022_min.pdf)
- [3] M. Mathys, "Food Nutrients Dataset," *Hugging Face Datasets*, 2023. [Çevrimiçi]. Erişim: <https://huggingface.co/datasets/mmathys/food-nutrients>

### Modeller ve Kod Kütüphaneleri (Models & Codes)

- [4] J. Bai, S. Bai, S. Yang, et al., "Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond," *arXiv preprint arXiv:2308.12966*, 2023.
- [5] G. Jocher, A. Chaurasia, ve J. Qiu, "Ultralytics YOLOv8," *GitHub*, 2023. [Çevrimiçi]. Erişim: <https://github.com/ultralytics/ultralytics>
- [6] E. Hu, Y. Shen, P. Wallis, et al., "LoRA: Low-Rank Adaptation of Large Language Models," *International Conference on Learning Representations (ICLR)*, 2022.
- [7] Microsoft, "GraphRAG: Graph-based Retrieval Augmented Generation," *GitHub*, 2024. [Çevrimiçi]. Erişim: <https://github.com/microsoft/graphrag>

### İlgili Literatür (Related Work)

- [8] L. Bossard, M. Guillaumin, ve L. Van Gool, "Food-101 -- Mining Discriminative Components with Random Forests," *European Conference on Computer Vision (ECCV)*, Zürich, 2014, ss. 446-461.
- [9] A. Myers, N. Johnston, V. Rathod, et al., "Im2Calories: towards an automated mobile vision food diary," *IEEE International Conference on Computer Vision (ICCV)*, Santiago, 2015, ss. 1213-1221.
- [10] H. Liu, C. Li, Q. Wu, ve Y. J. Lee, "Visual Instruction Tuning," *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.